TUGAS PERTEMUAN 6 MLOPS

MODEL EXPERIMENTATION & TRACKING IN MLOPS

Eksperimen CNN pada dataset Fashion-MNIST
dengan MLflow, Optuna, dan DVC

Nama	Devi Rahayu
NIM	123450010
Kelas	RA
Mata Kuliah	MLOps

1. Pendahuluan

Eksperimen machine learning tidak hanya berfokus pada pelatihan model, tetapi juga perlu mencatat konfigurasi, metrik, artefak, dan versi data agar hasilnya dapat ditinjau kembali. Praktikum ini menerapkan alur eksperimen CNN pada Fashion-MNIST, dengan MLflow untuk pencatatan eksperimen dan registrasi model, Optuna untuk pencarian hyperparameter, serta DVC untuk mencatat versi dataset.

1.1 Tujuan

1. Membangun model CNN baseline dan mencatat parameter serta metriknya di MLflow.
2. Melakukan tuning hyperparameter menggunakan Optuna dengan 24 trial.
3. Mengevaluasi konfigurasi terbaik menggunakan tiga seed.
4. Membandingkan komponen model melalui ablation study.
5. Mendaftarkan model ke MLflow Model Registry dengan alias `champion` dan menguji pemuatan model.
6. Mencatat metadata versi dataset menggunakan DVC.

1.2 Lingkungan dan data

Komponen	Hasil
Python	3.13.15
PyTorch	2.11.0+cu130
MLflow	3.17.0
Optuna	5.0.0
Scikit-learn	1.6.1
DVC	3.67.1
Perangkat komputasi	GPU Tesla T4 (CUDA tersedia)
Dataset	Fashion-MNIST; subset 6.000 data training dan 1.000 data testing

Dataset Fashion-MNIST terdiri dari citra pakaian grayscale berukuran 28 × 28 piksel dengan 10 kelas. Pada eksperimen ini digunakan subset agar proses pelatihan dan tuning dapat diselesaikan dalam waktu praktikum.

2. Metode dan alur eksperimen

Alur eksperimen dimulai dari persiapan lingkungan dan data, pelatihan baseline CNN, pencarian hyperparameter, evaluasi beberapa seed, ablation study, registrasi model, pengujian model terdaftar, lalu pencatatan metadata dataset menggunakan DVC.

2.1 Model baseline

Model yang digunakan adalah CNN bernama `FashionCNN`. Konfigurasi baseline menggunakan seed 42, 3 epoch, batch size 128, learning rate 0,001, dropout 0,25, dan batch normalization aktif. Optimizer yang digunakan adalah Adam dengan loss Cross Entropy.

3. Hasil eksperimen

3.1 Baseline CNN

Hasil pengujian baseline menunjukkan peningkatan akurasi pada setiap epoch. Akurasi pengujian tertinggi pada pelatihan baseline tercatat sebesar 87,70% pada epoch ketiga.

Epoch	Train loss	Train accuracy	Test accuracy
1	0,6465	77,45%	83,10%
2	0,3535	87,40%	87,30%
3	0,2708	90,07%	87,70%

3.2 Hyperparameter tuning dengan Optuna

Optuna menjalankan 24 trial dengan durasi 2 epoch pada setiap trial. Nilai akurasi validasi terbaik yang tercatat adalah 87,60%. Parameter terbaik yang diperoleh ditampilkan pada tabel berikut.

Hyperparameter	Nilai terbaik
Learning rate	0,0005185765
Batch size	128
Dropout	0,2173112
Batch normalization	Aktif (True)

3.3 Evaluasi dengan tiga seed

Konfigurasi terbaik diuji menggunakan seed 42, 123, dan 2026. Rata-rata akurasi pengujian adalah 87,20% dengan standar deviasi 2,26 poin persentase. Perbedaan hasil antarseed menunjukkan adanya variasi performa ketika inisialisasi dan proses pelatihan berubah.

Seed	Accuracy	Loss
42	87,80%	0,3522
123	84,70%	0,4163
2026	89,10%	0,3492
Rata-rata	87,20%	0,3726
Std. deviasi	2,26 poin persentase	0,0379

Catatan interpretasi: nilai akurasi tuning terbaik (87,60%) merupakan nilai terbaik selama proses pencarian, sedangkan rata-rata tiga seed (87,20%) berasal dari evaluasi terpisah. Keduanya tidak harus sama karena pengujian dilakukan pada proses yang berbeda.

4. Ablation study

Ablation study dilakukan dengan membandingkan konfigurasi model penuh terhadap konfigurasi yang menghilangkan satu komponen. Komponen yang diuji meliputi augmentasi data, dropout, dan batch normalization.

Konfigurasi	Accuracy	Loss
Model penuh	87,20%	0,3821
Tanpa augmentasi	88,20%	0,3441
Tanpa dropout	86,80%	0,3710
Tanpa batch normalization	77,60%	0,5871

Pada percobaan ini, konfigurasi tanpa augmentasi memperoleh akurasi tertinggi, yaitu 88,20%. Hasil tersebut menunjukkan bahwa augmentasi yang digunakan belum meningkatkan akurasi pada konfigurasi dan subset pengujian ini. Penghilangan dropout menurunkan akurasi sedikit menjadi 86,80%, sedangkan penghilangan batch normalization menurunkan akurasi lebih besar menjadi 77,60%. Kesimpulan ini terbatas pada satu rangkaian eksperimen dan tidak dapat langsung digeneralisasi ke seluruh dataset atau arsitektur CNN.

5. MLflow Model Registry dan pengujian

Model akhir didaftarkan ke MLflow Model Registry dengan nama `Devi_FashionMNIST_CNN`. Output notebook menunjukkan model versi 1 dibuat dan alias `champion` ditetapkan. Model kemudian dimuat menggunakan URI alias tersebut dan digunakan untuk menghasilkan prediksi.

Item	Hasil
Registered model	Devi_FashionMNIST_CNN
Versi	1
Alias	champion
Status uji muat	Berhasil
Pemeriksaan prediksi	10 label awal yang ditampilkan sama dengan label aktual pada output notebook

Pencatatan MLflow memudahkan penelusuran run, parameter, metrik, dan artefak model. Alias champion memberikan penamaan yang stabil untuk merujuk model yang dipilih, tanpa harus menuliskan nomor versi secara langsung di kode pemanggil.

6. Versioning dataset dengan DVC

DVC berhasil diinisialisasi pada direktori proyek. Dataset Fashion-MNIST kemudian diunduh ke folder proyek dan perintah `dvc add data` berhasil membuat file `data.dvc`. Metadata tersebut mencatat direktori data, hash, ukuran, dan jumlah file.

File `data.dvc` dan file dokumentasi proyek dimasukkan ke dalam ZIP. Pada hasil yang tersedia, DVC masih digunakan secara lokal; remote storage belum dikonfigurasi. Dengan demikian, langkah versioning lokal berhasil, tetapi sinkronisasi data ke penyimpanan remote belum dilakukan.

7. Ringkasan file dan keterbatasan

Berdasarkan ZIP yang disertakan, berkas pendukung yang tersedia adalah:

Berkas	Fungsi
README.md	Penjelasan singkat tujuan, alur, dan isi proyek.
requirements.txt	Daftar pustaka Python yang diperlukan.
experiment_summary.json	Ringkasan konfigurasi dan hasil utama eksperimen.
data.dvc	Metadata tracking dataset oleh DVC.
.dvcignore	Aturan pengecualian untuk DVC.
Notebook .ipynb	Kode eksperimen beserta output yang tersimpan.

Beberapa batasan yang perlu diperhatikan

• Eksperimen dijalankan di Google Colab. Berkas tracking lokal MLflow pada runtime Colab tidak otomatis menjadi server tracking permanen setelah runtime berakhir.
• ZIP pendukung tidak menyertakan cache dataset DVC karena ukuran data dipisahkan dari paket kode. File `data.dvc` adalah metadata, bukan salinan dataset itu sendiri.
• Notebook berisi output eksperimen yang menjadi sumber angka di laporan. Screenshot terpisah dari MLflow Compare Runs, grafik learning curve, registry, dan lineage tidak ditemukan dalam ZIP yang diperiksa; bila instruksi dosen secara khusus meminta screenshot, lampirkan bukti tersebut secara terpisah.

8. Kesimpulan

Praktikum ini berhasil menjalankan eksperimen CNN pada subset Fashion-MNIST dengan pencatatan baseline di MLflow, tuning 24 trial menggunakan Optuna, evaluasi konfigurasi terbaik dengan tiga seed, serta ablation study. Akurasi baseline pada epoch terakhir mencapai 87,70%, sedangkan akurasi validasi terbaik selama tuning adalah 87,60%. Rata-rata akurasi pengujian dari tiga seed mencapai 87,20%.

Model akhir juga berhasil didaftarkan sebagai `Devi_FashionMNIST_CNN` versi 1 dengan alias `champion` dan berhasil dimuat kembali untuk prediksi. DVC berhasil membuat metadata tracking dataset secara lokal melalui file `data.dvc`. Secara keseluruhan, rangkaian utama eksperimen dan tracking telah dijalankan, dengan catatan bahwa remote storage DVC dan screenshot bukti terpisah belum tersedia pada berkas yang diperiksa.

Referensi

1. MLflow Documentation. Tracking, Model Registry, dan PyTorch model logging. https://mlflow.org/docs/latest/
2. Optuna Documentation. Hyperparameter Optimization Framework. https://optuna.readthedocs.io/
3. DVC Documentation. Data Version Control. https://dvc.org/doc
4. Xiao, H., Rasul, K., & Vollgraf, R. (2017). Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. arXiv:1708.07747.